知 衡

多模态数据驱动的可解释精准问数问答智能体

技术实现说明书

中国电子杯　赛题八
网信产业应用赛道

2026 年 10 月

摘　要

知衡将数据库查询、文档检索与多源计算组织在同一问答工作区中。用户选择资料并提出问题后，系统生成受限计划，通过实际 SQL 执行、原文检索、参数与单位核对形成答案，同时保留来源版本、查询语句、引用位置、计算步骤和多轮父链。实现采用 React 与 TypeScript 前端、FastAPI 本地服务及 Python 分析模块，支持 1 至 12 来源范围和基于真实父轮的条件修改、澄清与假设撤销。

技术实现重点包括词法 Schema Linking 与外键桥扩展、只读 SQL 执行及独立语义核验、保留结构位置的切片与 BM25/E5 混合检索、有界缺项补检，以及绑定实际格值和原文规则的 Decimal 计算。资料事实、用户假设和派生结果分别记录，未解决项与已发布结论分开呈现。

开发验收保存 45 个场景的有效通过记录、86 次提交尝试和 545 次内部模型请求。三条链各 6 轮，采用修复后有效记录及真实父链。12 份完整技术原件共 2965 页，其中 6 份超过 200 页。24 题开发检索回归在全 12 文档范围 Top10 命中 24/24、必要页找齐 29/29，但该指标不等于端到端问答准确率。基础 SQL 与单文档 RAG 有效记录的端到端中位数分别为 7.2915 秒和 9.0425 秒。

这些结果来自分阶段开发与定向复测，未进行同一最终版本的 45 题全新重跑。本次实机展示的长文档时延、跨源依据不足和两次整体超时单独记录。报告保留表格结构恢复、复杂上下文槽位、输出表达与平台实机验证边界，提供完整问题、发布答案、原件和失败历史的复现入口。

关键词：自然语言问数；检索增强生成；跨源计算；证据绑定；多轮上下文

目　录

1 系统范围与实现架构.....4
1.1 问答对象与处理边界.....4
1.2 服务接口与不可变分析记录.....4
1.3 数据资产与使用方式.....6
2 NL2SQL 与 Schema 定位.....7
2.1 从问题要素到可执行计划.....7
2.2 词法 Schema Linking 与外键桥.....8
2.3 只读执行与 SQL 契约.....9
2.4 多表粒度与结果核对实例.....9
3 文档解析与 RAG 证据链.....10
3.1 解析结果必须保留原件位置.....10
3.2 切片与混合检索.....11
3.3 引用绑定与缺项补检.....12
3.4 复杂文档的代表问题.....13
4 跨源规划与可解释计算.....13
4.1 工具动作与依赖顺序.....13
4.2 参数来源与单位归一化.....14
4.3 原页公式与用户假设.....15
4.4 发布状态与异常保留.....15
5 上下文管理与来源解释.....16
5.1 父轮与条件变更.....16
5.2 假设与原事实的分离.....17
5.3 三条六轮链的核验结果.....18
5.4 可解释性在界面中的落点.....18
6 技术难点与完成程度.....19
6.1 关键问题的实现与证据.....19
6.2 复杂资料与鲁棒性边界.....20
7 测试设计与结果形成.....21
7.1 场景组织与独立判定.....21
7.2 有效记录与失败历史.....22
7.3 本地效率与端到端时延.....23
7.4 请求用量与新增演示.....24
8 运行环境与复现.....26
8.1 启动与配置.....26
8.2 从结论回到证据.....27
参考文献.....28

1 系统范围与实现架构

1.1 问答对象与处理边界

知衡面向同时存在结构化数据和长文档的业务问答。用户先选定工作区和资料，再提出问题；系统根据数据类型形成查询或检索计划，以实际执行结果和原文证据约束答案。一次分析可包含 1 至 12 个来源，后续追问沿真实父轮继续。回答保留来源版本、SQL、引用、计算步骤和上下文变更，使读者能够从结论返回依据。本文说明提交源码的实现机制与已经取得的开发验收证据。官方赛题对自然语言问数、文档问答、跨模态处理、可解释性和多轮交互提出要求，初赛要求至少一项中级功能及连续超过 5 轮的准确交互[1]。

系统使用 React 与 TypeScript 组织桌面交互，FastAPI 提供本地 API，Python 模块承担数据解析、问答编排与核验。结构化源主要为 SQLite 数据库，也支持导入表格形成受控查询对象；文档经解析和索引后参与检索。模型连接承担问题理解、候选生成和独立语义核验，本地程序负责来源身份、SQL 权限、引用位置、数值绑定和发布状态。没有模型连接时可以查看随包资料和历史证据；新的模型问答仍依赖已配置的服务。

本项目不把“能生成文字”作为完成条件。数据库问题要区分查询执行与业务语义正确，文档问题要区分找到了片段与完整回答了问题，跨源问题还要保留参数、规则和单位的各自来源。系统对缺条件、缺证据、取消和失败分别记录；已有正确的部分结论不能被未核实的候选覆盖。对于无法支持的关系或范围，答案保留未知项，不用常识填补原件缺失。

1.2 服务接口与不可变分析记录

问答入口接收 question、source_ids、mode、request_id，以及可选的 parent_answer_id、context_patch 和 expected_context_revision。服务首先检查工作区归属、来源可用性、数量上限与父轮身份，再建立任务。request_id 用于识别重复提交，父轮和上下文版本用于约束从哪一次分析继续。后台采用有界执行池，当前实现为 2 个工作线程与 16 个等待任务；该配置限制本机资源占用，不构成并发吞吐能力的测试结论。

系统总体架构：从提问到可核对的发布结果



图 1　系统总体架构

AnswerService 在开始时冻结来源快照，并核对原件摘要。运行期间选择数据库、文档或复杂工具路径，结束前再次检查来源是否变化。只有通过对应核验的内容才交给答案组装器发布，运行记录同时保存阶段事件、来源版本、完整结果表和模型请求用量。文件导入和解析通常先于问答完成，不会为了每个问题重新 OCR 整库。

这种设计使“用户现在看到的答案”具有明确身份。更换来源或修改口径产生新的分析记录，历史答案仍对应原来的来源与父链。保存、收藏和导出引用已发布结果，不把内部重试候选作为另一份正式结论。查询详情中的表级来源可以说明聚合用了哪张表；若没有逐行贡献证明，界面与导出就不声称精确追溯到了每一条贡献记录。

表 1　主要接口数据与核验作用

对象	关键字段	核验作用
问答请求	question、source_ids、mode	确定用户原话、资料范围与路径
分支与口径	parent_answer_id、context_revision	确定父轮；防止旧版本覆盖当前条件
来源快照	source_id、版本、摘要	开始与发布前确认原件身份
已发布结果	text、claims、result_tables	绑定正文、结论与完整表格

对象	关键字段	核验作用
过程记录	steps、evidence、calculations	解释执行、引用和参数来源
用量与尝试	model_attempts、usage、elapsed	保留每次内部请求及缺失项

1.3 数据资产与使用方式

验收资料分为三类。Chinook 与 Northwind 是教学数据库，边界测试数据库和站点巡检数据库用于检验同名对象、NULL、日期与多表关系等受控条件。合成文档用于固定库存阈值、人员角色和版本范围，能够明确判定答案是否遗漏条件。12 份真实技术资料用于检验长篇英文原件、表格、曲线、公式和跨页信息；其内容属于所列历史版本，不能被当作现行工程安全规范。

真实资料共 2965 个物理页，其中 6 份超过 200 页，最长 462 页。按完整出版卷或手册计数，未拆页、拼接或转换后重复计数。索引包含 13017 个切片。模型看到的证据仍受本次来源范围限制，资料库中存在某文件，并不代表用户已经授权当前问题使用它。合成口径说明、两个性能库与教学数据库单独登记，不计入 12 份真实资料。

表 2　真实技术原件范围

编号	资料名称	出版机构与年份	物理页
工程 A01	土与基础手册　卷一	FHWA 2006	462
工程 A02	地锚与锚固系统	FHWA 1999	304
工程 A03	浅基础	FHWA 2002	296
B01	热力学	DOE 1992	138
B02	传热学	DOE 1992	80
B03	流体流动	DOE 1992	82
B04	仪表与控制　卷一	DOE 1992	132
B05	仪表与控制　卷二	DOE 1992	168
B08	市政营养盐去除技术参考	EPA 2008	449

编号	资料名称	出版机构与年份	物理页
B10	紫外消毒指南	EPA 2006	436
B11	膜过滤指南	EPA 2005	332
B12	紫外处理技术审查工具包	EPA 2022	86

2 NL2SQL 与 Schema 定位

2.1 从问题要素到可执行计划

数据库问答首先把当前原话与有效上下文结合，确定对象、指标、过滤条件、时间范围、分组、排序、输出字段和缺失值规则。例如“只看至少卖出过一首曲目的艺术家，他们名下总曲目数超过 50”包含两个不同条件：销售记录决定艺术家是否具备资格，总曲目数则覆盖其全部曲目。这两个范围如果在一个销售明细 JOIN 中直接计数，会改变统计对象。

计划生成前建立数据库结构描述，保留表、列、主键、声明外键和有限样例值。系统可以进行最多 3 次有界结构或数据探查，用于确认实体歧义及候选字段含义。探查结果必须来自实际数据库，不能由模型补写。必要条件仍不明确时返回澄清选项；如两名员工同叫“张伟”，先询问门店和编号，不能因某一条记录排在前面就选定该人。

计划和执行结果分别核对。生成 SQL 只是候选步骤，后续还检查查询的表集合、过滤条件、总体与粒度、量词、NULL 处理和输出契约。若确实缺少用户条件，状态是待澄清；若计划自相矛盾、SQL 无效或证据不足，则保留对应失败原因。局部修正有次数与资源边界，不能以无限生成覆盖一次错误。



图 2　NL2SQL 流程

2.2 词法 Schema Linking 与外键桥

Schema Linking 将自然语言中的业务词映射到真实数据库对象。当前实现使用表列名称词法匹配、用户已经确认的业务别名和有界列值检索，明确记录 embedding_used=False。文档检索使用本地向量模型，不代表数据库结构定位也使用了向量模型；报告将两者分开说明，以便复现者准确理解依赖和计算成本。

当数据库表数不超过 16 时，系统保留表集，不为了展示“检索过程”删去可能相关的表。超过 16 表才先做候选召回与选表，再在声明外键图上补齐连接所需的中间表。外键桥搜索有最大跳数限制，当前为 8。补桥的作用是让两个有明确关系的实体可以通过真实外键相连，不能据同名字段臆造业务关系。

确认别名与候选定义分开存储。模型提出的“销售额”等业务解释可作为候选，但不会自动变为用户已经认可的统一口径。来源版本变化后，旧别名或值提示也需要重新判断适用性。这样可以减少问题改写时把旧定义带入新数据的风险，同时保留用户明确确认的业务知识。

该方法在当前规模下便于审计，但仍有适用边界。复杂缩写、跨语言业务同义词和没有声明外键的数据库可能召回不足；大表的有限样例也不能证明所有值都已覆盖。此时应补充 Schema 说明或由用户确认口径，不能将未命中等同于该实体不存在。

2.3 只读执行与 SQL 契约

SQL 安全检查与语义核验承担不同职责。执行器先解析 SQL 语法树，限制允许的语句、数据库对象和函数，再用只读 URI 打开数据库，并启用 query_only、trusted_schema=OFF 与防御设置。严格关闭双引号字符串兼容行为，可避免拼错列名被当作字符串常量而静默返回结果。authorizer 仅允许读取导入的普通表及许可操作，执行过程另有限时、指令步数、返回行数和单元格大小限制。SQLite 官方 API 也将 authorizer 定义为编译阶段的权限检查机制，并建议配合资源限制使用[2]。

仅有只读连接并不能证明查询回答了用户的问题。执行成功后，机械契约核查必需输出列、排序、量词与 NULL 等可计算约束，独立语义核验再检查业务含义。例如“严格超过 10 分钟”应为 Milliseconds>600000，而不是大于等于；“Company 不是 NULL”也不能擅自扩展为去掉所有空字符串。安全校验拒绝危险操作，语义核验防止安全但错误的查询被当作正确答案，两项缺一不可。

执行器可以缓存确定性的机械处理结果，但缓存键需要反映来源身份和输入。来源改变后旧结果不能继续当作当前证据。任何缓存或局部修正都不能省略最终来源变化检查，也不能让取消后的任务再次发布。系统保留实际 SQL 和完整结果表，便于用独立查询重新比较。

2.4 多表粒度与结果核对实例

sql-051 要求先判断艺术家至少有一首曲目售出，再统计名下全部曲目。正确实现要隔离销售资格和曲目总量，避免一首曲目因多条发票明细被重复放大，也不能只统计已售曲目。有效记录返回 12 位艺术家；文字预览展示前 6 行，完整 12 行保存在结果表。核验依据包括独立 SQL 和全部行值，不能只对照预览的几行便宣布整表一致。

sql-074 要求每个播放列表的不同专辑数，并保留没有曲目的列表。查询需保留 Playlist 侧的全部行，以 COUNT DISTINCT 统计实际专辑，空列表为 0。

同名但不同 ID 的列表保持独立，不能按名称合并。有效记录返回 18 行，并按列表编号排序。这个案例同时检验外连接、去重、实体身份和空关系，而不是仅证明 JOIN 语法能够执行。

sql-074 有效记录中的 SQL（仅增加换行）

```
SELECT p.PlaylistId AS "列表编号", p.Name AS "名称",
   COUNT(DISTINCT t.AlbumId) AS "专辑数"
FROM Playlist p
LEFT JOIN PlaylistTrack pt ON pt.PlaylistId = p.PlaylistId
LEFT JOIN Track t ON t.TrackId = pt.TrackId
GROUP BY p.PlaylistId, p.Name
ORDER BY p.PlaylistId ASC
```

表 3 SQL 代表问题与独立核对要点

编号	有效结果	容易出现的错误
sql-014	260 首；阈值 600000 毫秒	误用≥；忘记分钟至毫秒换算
sql-020	NULL 202 张；非 NULL 210 张	把缺失值补为其他类别
sql-051	12 位艺术家；含全部曲目	只算售出曲目；重复发票行放大数量
sql-074	18 个列表；空列表计 0	内连接丢空列表；同名列表合并

数值正确与呈现满足要求仍需分别判定。sql-041 的前五国家及数值、排序与独立查询一致，但历史发布文本将 195.10 和 190.10 显示为 195.1 和 190.1，没有完全满足两位小数展示。部分“只返回数量”问题也带有字段说明。技术验收中的有效通过记录保留这些表现问题，不把语义通过写成所有输出格式均完美。

3 文档解析与 RAG 证据链

3.1 解析结果必须保留原件位置

RAG 首先要回答证据来自哪里。PDF 采用物理页定位，DOCX 保留段落、章节和表格结构，文本资料保留可核验片段。解析记录保存来源身份、文本范围和结构标识，标题继承使用解析得到的真实层级，避免把外观相似的一行误

当作章节。分块既控制模型上下文长度，也需要保留解释一个数值所必需的表头、单位与适用对象。

原件页码、印刷页码与界面的逻辑章节可能不同。报告对 PDF 使用物理页数，引用显示时保留所用位置类型，不能把 DOCX 逻辑节号写成 PDF 物理页。原文文本引用通过精确片段与位置校验后，才成为生成和复核可引用的证据。页面图像用于曲线、公式或图形关系时，应保留实际页与区域身份。

OCR 补足扫描页文字，但识别出字词不代表恢复表格结构。行列归属、跨页表头、合并单元格和脚注可能需要额外识别与核对。现有 B11 栅格表验证中 table_count 为 0，系统没有恢复完整表关系；这项限制不能被其他原生 PDF 表格案例的通过所覆盖。图像、OCR 和原生文本路径在质量记录中分别保留。

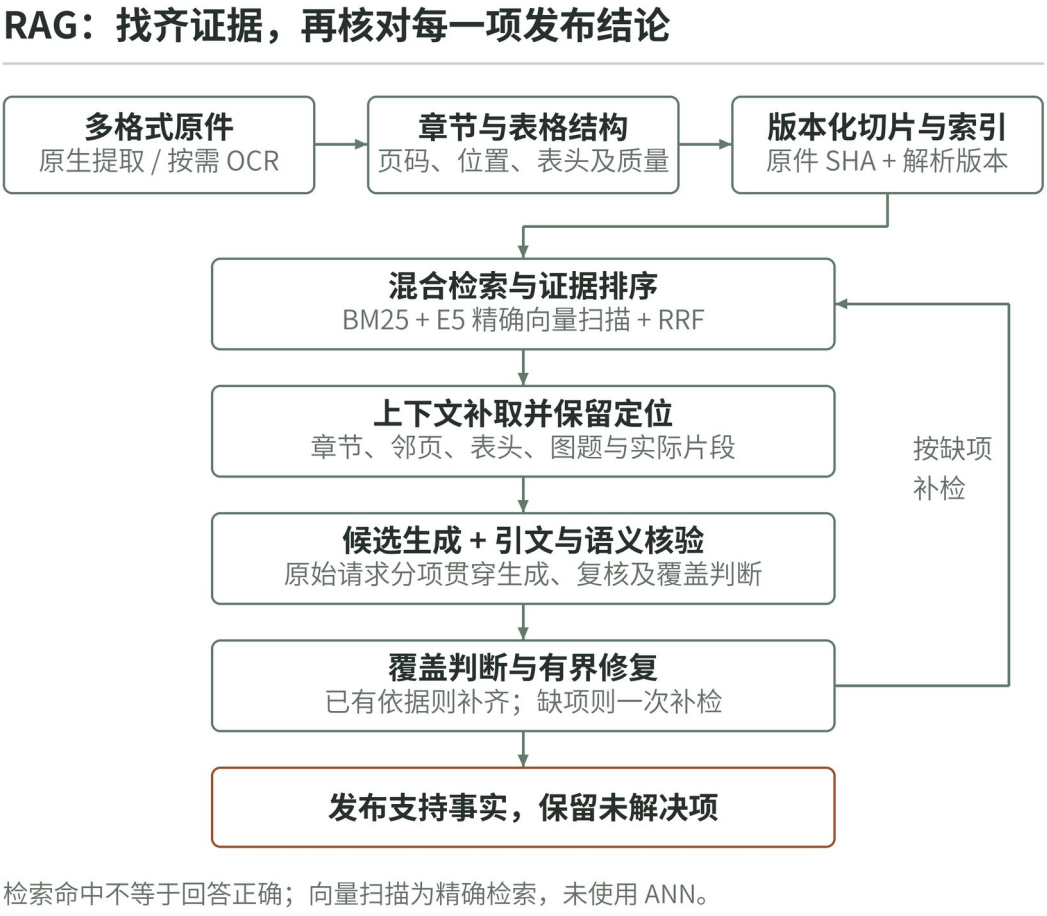


图 3　RAG 证据流程

3.2 切片与混合检索

文档切片保存 source、page、span 及表结构身份。检索先在用户选择的来源和页面范围内召回，再为候选片段补入必要章节、相邻页或表头。相邻页扩

展用于补齐语义，不表示附近任意文字都能支持结论。对于长表中的“平均值”，只有包含指标名称、单位和 Average 列关系的上下文才足以决定取值。

词法分支使用 BM25，本地向量分支使用 multilingual-e5-small。该模型为多语言 E5 系列中的小型嵌入模型，模型卡说明其维度为 384，输入有长度限制[3]。本实现按模型要求组织检索文本，并将分块控制与原文位置分开：为嵌入截断的文本不能成为“整页均已读懂”的依据。

向量检索按 256 行批次读取已存向量，计算精确余弦分数并保留 TopK。这里没有使用近似最近邻索引。hybrid 模式通过倒数排名融合 RRF 合并词法和向量候选，其基本形式为各列表中 1/(k+rank)的加和[4]。随后使用确定性的上下文排序器整理证据；它不是另一个神经重排模型，也不具备未实测的模型增益。

精确扫描的主要计算量随候选向量数 N 和维度 d 增长，约为 O(Nd)，维护 TopK 还需有界候选排序。分批读取限制了向量扫描环节的临时矩阵规模，不等同于整个进程内存仅为这一规模。当前 13017 个切片可以在本地完成检索，但更大语料的吞吐与内存表现仍需独立验证。

3.3 引用绑定与缺项补检

候选答案把主要事实拆为可核验的 claim，并指出支持它的证据。引用验证检查来源是否在本次范围内、文本是否真实存在、位置是否对应和数值是否来自支持片段。独立语义核验进一步判断证据是否足以支持结论。句子附近有一个引用并不意味着所有数字、因果或范围都得到支持，尤其不能用版本段落证明库存阈值，或用许可限值证明实测浓度。

完整性核验按问题中的各个要点记录覆盖情况。若已有正确证据却遗漏了一个要求，修正应使用现有证据补答；若缺少必要证据，则有界补检后再判断。当前普通文档路径允许一次有界修复，不让模型无限重复。仍未覆盖的要点留在未解决项或证据不足状态，避免把部分回答包装为完整完成。

发布阶段只选择真正通过的结论。内部候选即使语句流畅，也不能作为 published_claims 的兜底内容。完整结果、引用与核验状态保持一致，展示层可以调整布局和可读性，却不能静默改写历史答案事实、删除引用或隐藏失败尝试。这使原始结果与界面展示之间有可复查的对应关系。

3.4 复杂文档的代表问题

B08 的 Central Johnston County 案例要求同时区分设计处理能力、研究期实际平均流量、进出水 TN/TP 浓度与许可限值。已通过记录使用原 PDF 第 273 和 277 物理页，设计处理能力为 7 MGD，研究期为 2005 年 10 月至 2006 年 9 月，平均实际流量为 4.12 MGD；进出水 TN 平均浓度为 31.2 和 2.14 mg/L，TP 为 5.8 和 0.26 mg/L。浓度来自 Table 3 的 Average 列，不能与 Table 1 的许可限值或最大值混用[5]。

同一业务问题还扩大为 12 来源专项。系统最终定位到相关原件并回答 7 项事实，不要求把其余无关文档也塞进答案。该有效记录为第 5 次尝试，耗时 179.884 秒，包含 9 次模型请求，之前 4 次失败保留。两个来源范围不同的记录属于同一业务问题，不能据此增加独立问题数量，也不能从一次扩大范围成功推出全库稳定性。

B04 曲线案例比较约 400°C处 Nickel、Copper 和 Platinum 电阻高低，并结合正文说明 RTD 与热电偶测温原理。有效结果保留了 Nickel 高于 Copper、高于 Platinum 的顺序，核验重点是曲线关系和信号原理；没有把图上估读值写成精确电阻测量。图文联合回答所需的视觉依据与正文解释均应可回看。

表 4 24 题开发检索回归

检索范围	**Top10 问题命中**	**必要页找齐**	**含义**
同系列	24/24	28/29	1 题未找齐全部必要页
全 12 文档	24/24	29/29	24 题均找齐，仍须生成与复核

24 题开发检索回归中，全 12 文档范围 Top10 问题命中为 24/24，所需物理页找齐为 29/29；同系列范围问题找齐为 23/24、必要页为 28/29。它测量的是召回覆盖，不包含完整生成、引用绑定和答案语义判定。因此只能用于分析检索环节，不应称为 24 题端到端问答全对，更不能替代官方隐藏测试。

4 跨源规划与可解释计算

4.1 工具动作与依赖顺序

跨源问题需要把不同性质的依据连接起来。数据库提供实际字段值，文档提供规则、单位或条件，用户可以明确给出情景参数；计算引擎在这些绑定通

过后形成派生结果。复杂工具路径支持 search、sql、read_image、chart_read、formula_read 和 calculate 等动作。工具输出形成后续动作的依赖，模型不能在尚未取得 SQL 格值时自行填入一个“看起来合理”的参数。

规划器限制最大动作数为 32，并对连续 3 次没有实质进展的情况收束。新的文字改写不算进展；新证据、已执行计算、有效图像信息或覆盖推进才可支持继续。执行后生成候选结论，再对数值、来源、单位和覆盖做独立复核。工具成功只证明该动作完成，不直接等于整题正确。

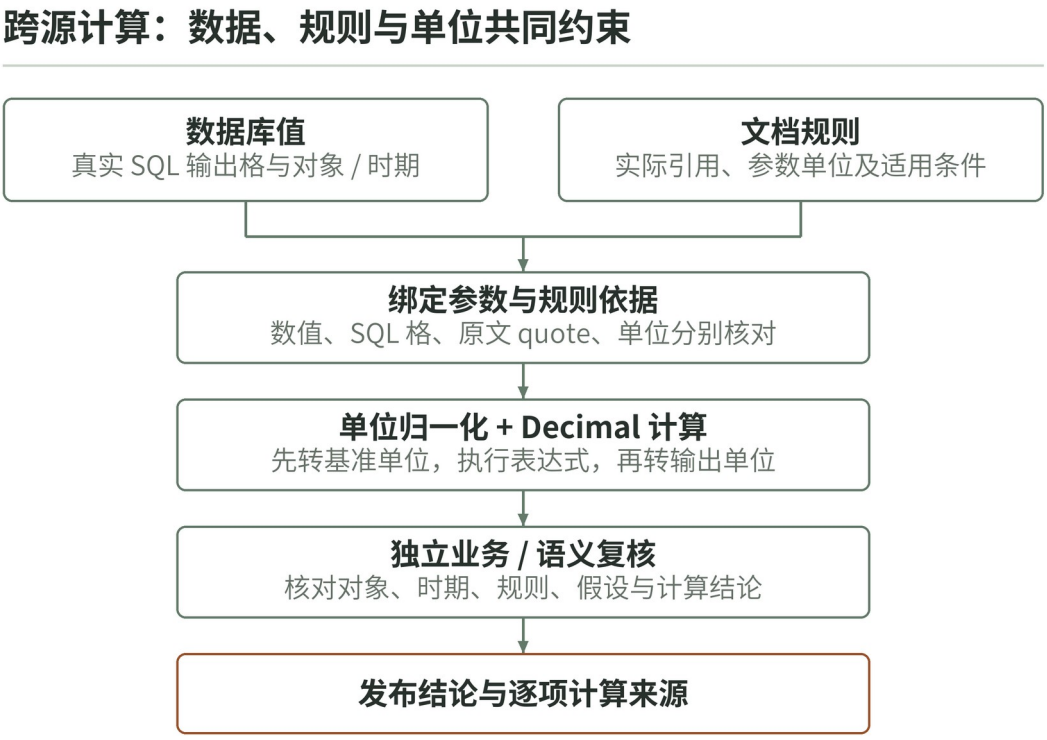


图 4　跨源计算

当前复杂工具规划从生成及相关复核开始使用 high 策略，普通 SQL 与简单 RAG 使用普通策略，明确且可信的多轮总结才在相应文档路径使用 high。原页或视觉工具仍保留自身设置。历史验收发生于分阶段修复期间，不能统一标成当前策略下运行；配置中的模型别名也不能认证服务背后的真实权重。

4.2 参数来源与单位归一化

计算协议将“值来自哪里”“单位如何确定”“计算规则由谁提供”分别记录。SQL 参数绑定实际结果表单元格，文档参数绑定原文片段及单位证据；

用户给定值则绑定真实原话，明确其假设性质。计算前检查参数名称与取值是否一致，规则引用是否充分，以及单位是否可以按已知关系转换。

公式执行使用 40 位精度的 Decimal。参数先归一到计算所需基准单位，再执行表达式，最后转换输出单位。这样可以避免浮点表示对金额和边界比较的影响，同时要求模型理解已经完成的归一化步骤。比如 10000 分在进入表达式前已按 100 分等于 1 元转换为 100 元，若表达式再除 100 就会发生二次换算。跨源第 6 轮的有效计算使用表达式 a，得到 100.00 元。

单位规则正确还不足以支持业务结论。原始金额筛选为 2024 年已完成订单，NULL 仍为未知；将所有年份或未完成订单混入，即使除以 100 的算术正确也无法回答原问题。计算结果因此同时保留 SQL 筛选、原字段、规则引用和处理后的参数，而不是只展示一个孤立算式。

4.3 原页公式与用户假设

工程 A01 公式问题使用 FHWA 手册点荷载试验说明中的常用关系 σc=24Is(50)。用户给定 Is(50)=2 MPa，代入得到估算单轴抗压强度 48.00 MPa[6]。系统需要同时保留公式所在页、符号含义、输入参数来自用户以及结果属于估算的性质。手册中的系数不能扩展成适用于所有岩石的普遍常数，岩性与校准条件仍影响适用性。

公式识别遇到上标、下标、分式和符号时，先核对结构，再进行运算。视觉读取产生的候选公式需要与原页关系核实；错误反馈只说明当前候选不合格，不能被当作支持另一条公式的新证据。对复杂图表和工程图，本项目已有代表案例，但没有取得任意 CAD 格式或所有扫描构件关系的通用识别证据。

跨源假设同样受来源区分约束。第 3 轮将 2024 实际金额 100 元假设减少 10%，得到 90 元；该数字不写回数据库。第 4 轮将 2025 实际 560 元与 2024 假设 90 元比较，差为 470 元，必须标明两者年份和实际或假设性质，不能称为实际同比变化。撤销后恢复 100 元，而不是继续沿用最近一次答案中的 90 元。

4.4 发布状态与异常保留

答案可以完成、需要澄清、证据不足、部分完成、取消或失败。状态来自真实执行和核验结果，展示层不能根据是否有文本就统一显示成功。来源中途变化时，正在运行的结果不能继续作为原版本证据发布；用户取消后也不应把后台迟到结果呈现为本轮已完成。

服务超时或返回未知结果时不自动重放可能已经送达的 POST。明确原因后发起的人工重试形成新记录，保留前次请求及失败状态。模型请求的 HTTP 成功与答案通过分开统计；例如历史 545 次请求中有 535 次 HTTP 200，这并不意味着 535 个正确回答，因为每个用户轮可能包含多次生成、探查和核验。

这种保留失败的方式增加了审核材料长度，却使修复效果能够被检查。跨源第 4 轮采用第 7 次尝试的有效记录，前 6 次失败仍可查看。报告据此说明已在受控场景中修复粒度、绑定或覆盖问题，不据筛出的最后成功结果推断一次成功率。

5 上下文管理与来源解释

5.1 父轮与条件变更

多轮上下文由真实答案父子关系承载，每轮保存 conversation_id、parent_answer_id、turn_index 和 context_revision。用户从某一历史答案继续时，新分支应接到被选择的那一轮，不能误用当前末轮。来源范围和版本也沿链核对，查看一个原件页面并不会扩展下一问的资料权限。

结构化条件支持 add、replace 和 remove。对象、时间、指标、分组、NULL 规则与用户假设可各自保留或变化。例如“改查东店编号 1，其余口径不变”只替换员工身份，工时求和和 NULL 未知规则继续有效；“撤销上一轮新增年份限制”则仅撤销年份条件，不能同时清除员工身份。

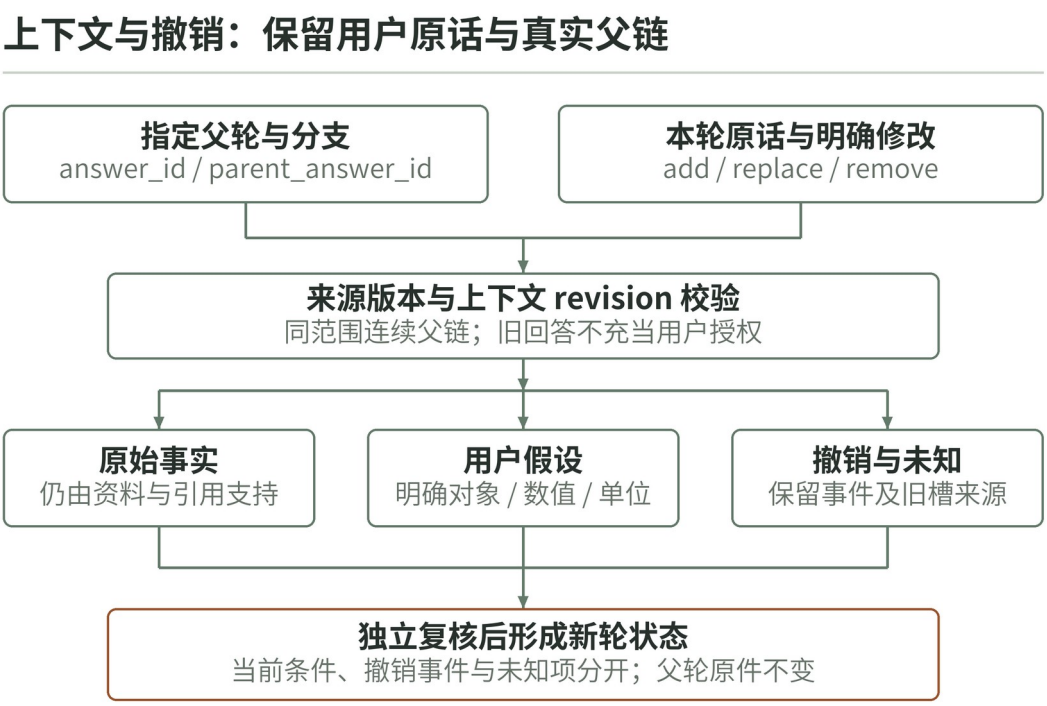


图 5　上下文与撤销

当前代码对模型遗漏与用户撤销作了专门区分。只有已完成、发布通过且所有相关字段经过独立核验后，旧模型槽位的遗漏才可投影为 unknown 并保留 previous_slot。用户撤销要有明确原话和对应变更事件。将遗漏一概当成“用户取消了条件”，会在后续轮次中无声扩大统计范围，因此不能这样处理。

5.2 假设与原事实的分离

文档上下文只接纳同来源的连续真实父链和用户原话，事件绑定 quote、span 与摘要。活动假设、已撤销假设和被替代假设分别记录。系统可以引用此前经过核验的结果继续分析，但历史答案本身不能代替用户授权，也不能成为一条新资料事实的唯一来源。

库存链中，原文实盘 11 件、台账 12 件，采购条件为严格低于 8 件。第 3 轮用户提出 7 件情景，系统在该假设下判断应申请；第 4 轮撤销后恢复 11 件，并保留 1 件差额原因未知。这里既要恢复数字，也要恢复数字的身份，避免把“模型最近说过 7 件”当成当前事实。

现有文档假设机制主要覆盖有限的简单数量设定，并非任意参数工作台。跨源第 3 轮的独立 assumptions 结构槽仍不完整，历史续接依赖可核验的真实原

话；同名员工第 5 轮取消年份后 time_range 仍编码为 unknown。核心结果和父链通过不等于所有结构化槽位表达均已完善。

5.3 三条六轮链的核验结果

三条链各 6 轮，核验时逐项检查父轮身份、会话、轮号、来源版本、实际发布文本和独立审核关联。采用已通过的前缀继续修复后续轮次，属于分阶段有效链。18 轮不与 45 个场景相加，因为这些轮次已包含在场景集合内。链中的澄清属于正确处理，不能写成第一轮已经给出最终数值。

表 5　三条真实六轮链的条件与结果

链	六轮推进	核验边界
同名员工	1 澄清身份；2 西店已知 2 小时；3 改东店 3 小时；4 加 2024 条件为 2 小时；5 撤销年份恢复 3 小时；6 比较已知差 1 小时，西店仍有 1 条缺失工时。	6/6；首次为正确澄清；保留 NULL 未知
文档库存	1 严格低于 8 件申请；2 实盘 11/台账 12；3 假设 7 件需申请；4 撤销回到 11 件；5 核版本与本站范围；6 汇总并说明假设已撤销。	6/6；第 6 轮表达重复且分段
跨源金额	1 2025 实际 560 元；2 改 2024 实际 100 元；3 减 10%假设 90 元；4 与 2025 实际差 470 元；5 撤销恢复 100 元；6 真实建议追问核参数与步骤。	6/6；第 4 轮为实际与假设比较

文档链第 6 轮覆盖库存、阈值、差额、版本、适用范围和假设已撤销等事实，实际回答仍分多段且有重复，未满足用户要求的“一段简明说明”。跨源第 6 轮通过真实建议接口产生下一问并被接受，实际问句为“说明这次已核对计算的参数来源与计算步骤？”。冻结计划中的动态占位从未作为实际问句发送，补充材料同时保存真实原话与建议来源。

5.4 可解释性在界面中的落点

解释以用户的核对动作组织：先读实际发布结论，再查看就近引用或结果表，最后按需展开 SQL、原文、计算和上下文变更。结论中的单位、未知值和条件与详情保持一致。表格展示完整行数，预览与导出范围明确；没有合适数值含义的日期或类别结果不强制绘制图表。

阅读与来源对照可以各自滚动。引用点击定位到实际证据位置，独立来源页返回时恢复原分析与正在输入的草稿。该交互不会伪造逐行同步，也不会把检索命中的片段自动升级为已核验结论。阶段事件可说明当前正在检索、查询或核验；没有可靠总量时只展示等待时长，不生成虚假的完成百分比。

最终桌面界面按阅读、结果对照和来源核对组织内容。实机展示完成 SQL 结果、文档原页和实体澄清的查看，并保存本轮草稿。发现失败答案旁仍显示续问文案后，前端统一以答案状态决定父轮资格：failed 和 cancelled 后的输入属于独立新问，提交时 parent 为空且不携带 context_patch；有效父轮与上下文版本继续保留，排队和运行中的任务不能重复提交。

该修复完成 63 项定向测试，其中新增 21 项。本次 Mac 原生 Chrome 与内嵌浏览器累计完成 15 项交互核验，覆盖范围选择、结果与原页对照、草稿、缩放、澄清等操作；最后一项在原生浏览器回放失败重试，确认独立新问提示、原问题全文填入、恢复先前草稿和不自动发送。界面核验只证明具体操作与请求边界；第 7 次真实提交已作为独立新问发出并最终失败，修正文案没有把它变成成功的父链续问。

6 技术难点与完成程度

6.1 关键问题的实现与证据

本项目的主要实现工作集中在异构证据之间的约束传递。NL2SQL 要防止连接后改变统计粒度，RAG 要防止一个片段只支持答案的一部分，跨源计算要防止字段值和单位规则脱离原件，多轮追问要防止假设或旧范围混入当前条件。这些约束最终都需要落到可记录的来源、参数或状态，单纯增加提示词强调不足以形成可复现的检查。

表 6 技术问题的完成程度

问题	实现与代表证据	当前程度
多表统计粒度	资格与统计总体分离；sql-051 全部 12 行独立核对	代表场景有效通过
长表范围与单位	B08 区分设计、实测和许可；原页 273/277	代表场景有效通过
公式与单位计算	公式结构核验、来源绑定、Decimal；A01 及跨源 t6	代表场景有效通过

问题	实现与代表证据	当前程度
条件修改与撤销	真实父链、变更事件、保留未知；三条 6 轮链	有效链通过；槽位仍有边界
扫描表格关系	OCR 文本与坐标保存，表关系单列质量检查	B11 栅格表未恢复
部署可迁移性	跨平台入口、文件锁、依赖、数据映射	Windows 静态核对；实机待验

实现中的取舍是保留可理解的有界过程。精确向量扫描在当前语料规模下便于复算，但规模扩大后会增加成本；独立核验能发现证据与答案之间的偏差，但增加请求与时延；有限补检降低无限循环风险，却可能让复杂问题以证据不足结束。报告不把这些取舍掩盖为“所有问题自动完成”，而是通过真实状态告诉使用者下一步需要补什么。

6.2 复杂资料与鲁棒性边界

目前已取得原生表格多指标核对、曲线相对高低、原页公式代入和 12 来源范围问答等有效案例。这说明相应实现可以在给定原件上工作，但覆盖面仍受解析质量与模型判断影响。B11 栅格表结构未恢复；OCR 存在文字和版式关系脱节；缺失或不可靠的表头会直接影响数值归属。当前不声明任意 CAD 解析能力，也没有把工程图截图等同于真实 CAD 文件输入。

输入鲁棒性有一个受控错字专项，将“成功启冻”按语境理解为成功启动，并正确回答 18 次成功、2 次失败及全部启动次数作为分母。该证据只覆盖这一次错字，并不代表所有噪声输入均经过测试。模糊实体、未给时间、来源冲突或版本不明仍需要澄清或保留未知，不能为了给出答案而主动替用户选择。

可追溯性也有粒度限制。SQL 聚合结果通常能够追溯到表、查询条件和执行记录；若没有贡献行清单，不能声称每个合计都可直接定位到全部贡献行。文档证据中可验证的引用不自动证明原件事实在现实世界中仍有效，尤其归档手册仅用于所列版本的问答验证。

7 测试设计与结果形成

7.1 场景组织与独立判定

测试采用冻结问题、实际调用记录与独立核对相结合的方式。原 20 题顺序和编号保持不变，其中 8 题为单表 SQL、2 题为多表 SQL、10 题为单文档 RAG。单表计分组另补 sql-002 和 sql-003，共 10 题；补充题没有替换原 20 中的多表题。专项增加真实复杂资料、12 来源、错字和三类连续追问。45 个场景只有 44 个不同问句，因为 B08 问题在单文档与 12 来源中分别使用。

SQL 按独立查询核对全部结果行，文档按原件逐项核对事实、来源与适用范围，计算按原值、单位和表达式复算，多轮按真实父链核对条件继承与撤销。completed 只是运行状态，不足以构成通过。独立审核以实际发布文本和完整结果表为对象，内部候选即使包含正确答案也不能用于替代发布结果。

表 7　原 20 题固定编号与有效结果概览

编号	类别	有效结果概括
sql-001	单表	Track 3503 条
rag-003	RAG	紧急三短鸣；到岗一长鸣
sql-004	单表	Total 合计 2328.60
rag-008	RAG	成功 18、失败 2；分母全部启动
sql-006	单表	24 个国家分组，完整表一致
rag-012	RAG	3 个独立水样；复测不增样本
sql-009	单表	Composer 为 NULL 977 条
rag-020	RAG	断面、时间、仪器批次
sql-014	单表	严格超过 10 分钟 260 首
rag-023	RAG	温升 7.5℃；室温 22℃
sql-017	单表	Company 非 NULL 10 人
rag-028	RAG	RX-9B、C12、青石
sql-020	单表	NULL 202；非 NULL 210
rag-032	RAG	单程通勤；不含接送绕行
sql-041	单表	国家销售额前五及排序一致

编号	类别	有效结果概括
rag-038	RAG	不包括未开工项目
sql-051	多表	12 位艺术家，全部曲目数一致
rag-044	RAG	签发 7 月 3 日；涉及 7 月 1 日日报
sql-074	多表	18 个列表，空列表 0 专辑
rag-049	RAG	区分审核复核；操作员未知

补充单表题单列：sql-002 返回不同国家数 24；sql-003 返回最早 2021-01-01 00:00:00、最晚 2025-12-22 00:00:00。原 20 题及其顺序没有替换。

完整问题、预期依据、实际发布全文、完整表格、引用、有效尝试与失败历史保存在评审导读和详细对照中。表中概括用于定位，不替代原始答案。受控资料中的人名、站点和记录是合成测试内容，不代表参赛者身份或真实企业数据。

7.2 有效记录与失败历史

现有 45 个场景均有独立核验通过的有效记录，来自分阶段开发、失败修复和定向复测。总计 86 次提交尝试，其中 84 次发生模型请求，2 次只在本地终止或处理。29 个场景选用首次记录，16 个场景选用后续记录，另有 41 条未选用尝试保留。由于版本和修复过程不同，这些数值不能解释为单一模型的首答准确率。



图 6　结果与证据口径

本次交付整理以原件摘要、记录关联和字段比对复核已有证据，没有重新调用模型完成 45 题全量测试。核对包括 86 条尝试原件身份、45 条发布正文及结果表、独立审核文件关联和 18 轮父子关系。它证明材料可以回到原记录，不产生一个新的模型准确率结论。历史 3678 项离线测试及后续 58、183 项检查处于不同修复阶段，部分范围重叠，不能相加成最终版本测试总数。

失败修复保留能够解释结果的实例。12 来源专项到第 5 次才通过，跨源比较到第 7 次，文档六轮总结到第 5 次。原因涉及证据覆盖、数值绑定、结构化上下文和输出表达。修复后有效记录用于说明相应冻结场景已可通过；尚未取得同一最终代码、全新会话、全部 45 题重新运行的稳定性证据。

7.3 本地效率与端到端时延

SQL 性能实验使用受控 1000 行与 10000 行数据库，对同类聚合及索引筛选查询进行比较。每种配置记录首次执行，再取后续 5 次的中位数。首次执行未清除操作系统文件缓存，因此不能称为严格冷启动。该实验衡量本地执行器开销，不包含模型生成或语义核验。

表 8 不同层次的性能测量

层次与任务	规模	中位耗时	测量口径
本地 SQL 聚合	1000 行	1.007833 ms	后续 5 次中位数
本地 SQL 聚合	10000 行	2.418541 ms	同类受控查询
本地索引筛选	1000 行	0.675583 ms	不含模型请求
本地索引筛选	10000 行	1.800875 ms	不含模型请求
本地检索	同系列	240.5 ms	范围限制后的检索
本地检索	全 12 文档	776.5 ms	13017 切片
端到端基础 SQL	10 题有效记录	7291.5 ms	提交至答案发布
端到端单文档 RAG	10 题有效记录	9042.5 ms	提交至答案发布

10 题基础 SQL 有效记录的端到端中位数为 7.2915 秒，范围 4.502 至 19.096 秒；10 题单文档 RAG 为 9.0425 秒，范围 6.394 至 15.197 秒。两组与本地毫秒级测量处在不同层次，不能用本地查询耗时宣传整题响应速度。复杂跨源和 12 来源场景包含更多模型动作，不能套用基础题中位数。

阶段拆分显示，SQL 组模型请求耗时合计 91.391 秒，占端到端合计 94.052 秒的 97.17%；RAG 组为 92.441 秒，占 96.334 秒的 95.96%。请求时间包含网络、网关和服务处理，无法再拆成纯模型推理时间；剩余时间包括本地处理、轮询和记录导出。以上为串行开发验收记录，不提供并发吞吐、显存峰值或长期可用性结论。

7.4 请求用量与新增演示

86 次历史提交内部共记录 545 次模型请求，其中 467 次普通策略、78 次 high 策略。535 次请求有完整 usage，总计 8844583 个已报告 token；10 次缺失用量，不能按零补齐。HTTP 状态中 535 次为 200、2 次为 503、8 次未记录。一次用户问题可能经历生成、探查、修正和复核，统计时不能把 545 次内部请求说成 545 道独立问答。

按已核实网关目录价且不扣缓存折扣估算，已知用量约 10.572514 元；实际账单未知，这不是实扣费用。缓存 token 与推理 token 为服务上报字段，不能把缺失请求的花费也并入这一数字。提交材料使用这些数值说明开发成本边界，不推导商业部署的固定单题价格。

2026 年 10 月 19 日的实机展示另行登记。SQL 前五国家问题用时 10.633 秒、4 次内部请求，数值、完整 5 行和排序经原始 Invoice 行的 Decimal 复算一致；发布文本仍将两项金额末尾零省略。B08 单来源问题用时 519.465 秒、12 次请求，7 项核心事实及 6 段最终引用与第 273、277 物理页一致；其中 10 次 high、2 次普通，第 8 次输出截断保留。该长耗时不能被历史基础题中位数掩盖。

本次 2025 跨源金额首轮用时 455.942 秒、13 次请求，最终为 insufficient_evidence。实际 SQL 与 560.00 元机械计算正确，但年份 2025 的数值匹配误遮了完整日期 2025-01-01，导致控制器生成的候选被门禁拒绝。修复仅收紧数字片段边界，新增 12 项回归、相关 459 项离线检查通过；来源与独立语义核验仍保留。定向复演又在第 6 次请求达到 480.106 秒整体上限后失败，整轮 571.892 秒，未自动重复 POST，也未发布数值。这两次失败均未用内部正确候选冒充正式答案。

同名员工展示先用 6.648 秒、3 次普通请求正确澄清东店编号 1 与西店编号 2，再以真实父轮接受西店编号 2 的选择，用 14.261 秒、6 次普通请求返回已记录工时合计 2 小时。原库另有 1 条 NULL 工时，SQL 未补零，但正文没有说明该缺失条数，作为表达限制保留。

第 7 轮实际问题为“把年份改成 2024 年，其余口径不变，仍分别给出原始金额和换算为元的金额。”计划承接前轮，实际 parent_answer_id 为空、turn_index 为 1，未继承前轮条件。该轮 579.717 秒、6 次 high 请求，末次 480.064 秒触发整体超时，最终 failed；没有发布金额，也没有完成澄清。计划与实际父轮差异保留，不能把它写成条件继承或恢复成功。

本次 7 轮合计 50 次内部请求，其中 15 次普通、35 次 high；47 次请求完成、1 次输出截断、2 次超时。48 次已知用量共 1368224 个 token，2 次超时用量未知。用户轮状态为 3 次 completed、1 次 needs_clarification、1 次 insufficient_evidence 和 2 次 failed；这些是实际状态分布，不换算为系统准确率。模型别名与 high 参数不证明下层模型权重，实际账单仍未知。

上述记录用于展示当次运行、核对来源和暴露交付问题，不作为准确率、首答成功率或稳定性测试。历史 45 场景、三条六轮链与本次展示分别登记，日期修复前后的代码也分别保留。

8 运行环境与复现

8.1 启动与配置

交付包含最新前端 dist、Python 依赖锁、4 个业务或教学数据库及 Schema、受控口径文档、两个性能库、12 份完整真实资料、多格式样本、本地 E5 模型及许可说明。评委普通运行使用预构建前端，无需安装 Node 或完整前端开发工具。Mac 虚拟环境、node_modules 和用户运行缓存不作为可迁移依赖随包复制。

首次准备应使用项目提供的入口，在自己的目录中创建依赖环境；模型地址与凭据通过本机配置输入，源码及报告不携带真实密钥。随后启动本地服务并检查健康状态与工作区身份，再导入或选择样本。服务停止只能作用于已经确认属于当前项目的实例，不能仅凭端口或旧 PID 文件终止其他进程。

跨平台实现已将 Python 入口按平台切换为 Scripts/python.exe 或 bin/python，文件互斥分别采用 Windows 字节锁与 POSIX flock。进程管理核对源码目录、命令行、创建时间和健康状态，并以本地令牌绑定的停止请求优雅关闭服务。首次准备、启动、停止和环境检查提供中文 cmd 入口，按脚本目录定位并输出 UTF-8，不要求管理员或永久降低系统策略。严格 SQLite DQS 和只读约束保持启用。

2026 年 10 月 19 日完成 36 项启动、队列、锁及 PID 复用定向检查，CPython 3.13 与 Windows x64 条件下 45 项精确依赖轮子解析通过，包含 Windows 所需 colorama。Mac 当前源码的真实启动、健康身份、优雅停止和端口释放已核对。Windows 没有可用实机，因此安装、DLL 加载、ACL 执行、中文路径界面和 OCR 尚未在 Windows 实际运行；轮子解析只能证明依赖可解析，不能替代实机验收。Tesseract 文字与坐标输出也不等于扫描表结构恢复。

本次交接演练在全新解压源码目录和空运行目录中完成 Mac 启动、健康身份、空项目、前端资源 HTTP 逐字节比对与优雅停止，显式复用了本机已有依赖并禁用在线安装。随后前端失败提示修复形成最终源码包，868 项文件摘要及 ZIP 完整性检查通过，最后 JS、CSS 与实际服务响应逐字节一致。前序候选的启停演练与最终包资源复核分别留档；它们都不是纯净操作系统从零安装或 Windows、OCR 实机证明。

8.2 从结论回到证据

建议先打开评审导读，选择 SQL、长文档或跨源案例，核对原问题与实际发布结果。若要复算 SQL，再打开对应数据库和 Schema，按对照文件中的查询比较完整行值；若要核对文档，则依据资料清单中的原件名和物理页查看原文。对多轮案例，按父轮顺序阅读原话、状态变更和最终结论，不能把另一条尝试拼入链中。

可迁移评测副本使用相对路径并创建真实工作区及来源映射，不依赖开发机的 project-id。答案键与运行知识库分离，避免检索到预期答案而形成数据泄漏。只查看随包 HTML 与历史证据不会触发模型调用；主动运行新的问题会使用用户配置的连接，并形成新的记录，不能覆盖本报告所引用的历史结果。

表 9 包内复现入口与源码定位

对象	包内路径或模块	阅读目的
评审入口	00_评审导读.html	实际问句、发布结果、完整表格与链
运行过程	04_实测与过程/知衡全量问答对照与运行稳定性说明.md	尝试、失败、指标和统计边界
模型策略	04_实测与过程/当前模型调用策略.md	历史配置与当前角色策略
源码与资产	03_作品原始文件.zip	解压后依 README 启动与复现
数据库路径	backend/query_planner.py；sql_engine.py	生成、机械契约与只读执行
文档路径	backend/document_engine.py；retrieval/service.py	结构、检索、引用及完整性
跨源与上下文	backend/cross_source_engine.py；formula_engine.py；conversation_state.py	工具依赖、数值绑定与条件变更

参考文献

[1] 中电云计算技术有限公司. 赛题八 网信产业应用赛道 多模态数据驱动的可解释精准问数问答智能体[Z]. 中国电子杯官方赛题资料, 2026: 5-11.

[2] SQLITE. Compile-time authorization callbacks[EB/OL]. [2026-10-19]. https://www.sqlite.org/c3ref/set_authorizer.html.

[3] WANG L, YANG N, HUANG X, et al. Multilingual E5 text embeddings: A technical report[EB/OL]. (2024-02-08)[2026-10-19]. https://arxiv.org/abs/2402.05672.

[4] CORMACK G V, CLARKE C L A, BUETTCHER S. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods[C]//Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2009: 758-759. DOI:10.1145/1571941.1572114.

[5] U.S. ENVIRONMENTAL PROTECTION AGENCY. Municipal nutrient removal technologies reference document[R]. EPA 832-R-08-006. Washington, DC: U.S. EPA, 2008.

[6] FEDERAL HIGHWAY ADMINISTRATION. Soils and foundations reference manual: Volume I[R]. FHWA NHI-06-088. Washington, DC: U.S. Department of Transportation, 2006.