知衡
测试用例与实测说明

知衡的测试材料用于说明问题如何设定、结果如何判定，以及读者怎样从结论回到原始依据。本说明汇总已经完成的开发验收，不启动新一轮全量模型测试。45 个场景均保留有效通过记录及失败历史；新增实机展示单独登记，避免将少量演示写成全系统稳定性结论。

1 测试对象与判定方法

验收分为单表问数、多表查询、单文档检索问答、复杂资料、12 来源范围、错字输入和连续追问。输入冻结后记录问题、来源、父轮和预期要点；实际调用保存模型请求、发布状态、全文、结果表、引用和计算。判定对象是最终发布内容，内部候选或 completed 状态都不能单独作为通过依据。

SQL 结果用独立查询比较全部行值、字段、排序与 NULL 规则。文档答案对照原件核对事实、位置、单位和适用范围，同时检查是否回答全部要点。公式和跨源计算核对实际取值、规则来源、单位归一化、表达式和输出。多轮问题还要确认父轮真实连续、对象与条件修改正确、撤销后旧假设不再活动。正确澄清也是有效处理，但与已经完成数值回答分开记录。

资料类别分别统计：4 个业务或教学数据库及对应 Schema，合成口径与多格式受控样本，两个性能规模库，以及 12 份完整真实技术原件。真实原件共 2965 个物理页、6 份超过 200 页、最长 462 页，索引为 13017 个切片。历史手册仅按所列版本核验，不作为现行规范。重复路径指向的同摘要数据库不另计一份。

2 原 20 题与补充单表题

原 20 题顺序和编号完整保留，其中 8 道单表 SQL、2 道多表 SQL、10 道单文档 RAG。单表计分集合另外补入 sql-002 和 sql-003，形成 10 题。两道多表题没有删除或替换。表 1 列出原问句和应核对的主要结果，完整实际发布答案与表格在评审导读中可逐题展开。

表 1　原 20 题完整问题与核验要点

编号	原始问题	预期核对要点
sql-001	曲目表一共有多少条记录？只返回数量。	3503 条
rag-003	紧急撤离和普通到岗提示的鸣笛信号分别是什么？	紧急三短鸣；到岗一长鸣
sql-004	所有账单 Total 合计是多少？保留两位小数，只返回金额。	2328.60
rag-008	手册中的成功启动与失败启动次数各是多少，成功率分母怎样定义？	18 次、2 次；分母为全部启动
sql-006	按客户国家统计客户数量，输出国家和数量，按国家名升序。	24 国家，完整行值与排序一致
rag-012	每个断面有几个独立水样？实验室复测会增加这个数量吗？	3 份；复测不增加
sql-009	有多少首曲目的 Composer 为 NULL？只返回数量，不把空字符串当 NULL。	977 首
rag-020	复查必须保留哪三项标识？	断面编号、采样时间、仪器批次
sql-014	时长严格超过 10 分钟的曲目有多少首？请用 Milliseconds 正确换算。	260 首；严格>600000 毫秒
rag-023	M-028 的温升与室温分别是多少？	7.5℃、22℃
sql-017	客户表 Company 已填写、即不是 NULL 的客户有多少人？	10 人
rag-028	在日志尾部找到 M-080 备用继电器型号、保管柜和附件复核暗号。	RX-9B、C12、青石
sql-020	BillingState 为 NULL 和非 NULL 的发票各多少张？按 NULL 数量、非 NULL 数量输出。	202 张、210 张
rag-032	通勤时长是否包含接送子女绕行时间？	不含接送绕行
sql-041	按账单国家统计总销售额，金额保留两位小数，取最高的 5 个国家，输出国家和销售额。金额相同按国家名升序。	USA 523.06、Canada 303.96、France 195.10、Brazil 190.10、Germany 156.48

编号	原始问题	预期核对要点
rag-038	拟议补助对象是否包括尚未开工项目？	不包括未开工项目
sql-051	只看至少卖出过一首曲目的艺术家，他们名下总曲目数超过 50 的有哪些？输出艺术家编号、名字、总曲目数。总曲目数包括未售出的曲目。	12 位；全部曲目含未售出
rag-044	用电更正通知哪天签发，涉及哪天日报？	2025 年 7 月 3 日；涉及 7 月 1 日
sql-074	各播放列表有多少不同专辑？包括没有曲目的列表，输出列表编号、名称、专辑数，按编号升序。	18 列表；空列表为 0
rag-049	审核人和复核人分别是谁，能据此判断设备操作员吗？	审核唐溪、复核顾衡；操作员未知

表 2　补充单表题单独登记

编号	原始问题	核验结果
sql-002	客户来自多少个不同国家？只返回国家数，不把客户数当国家数。	不同国家数 24
sql-003	发票最早和最晚的开票日期是什么？按最早、最晚两列输出。	最早 2021-01-01 00:00:00；最晚 2025-12-22 00:00:00

sql-006、sql-051 和 sql-074 的历史正文只预览前 6 行，完整结果分别为 24、12 和 18 行，比较时必须打开结果表。sql-041 数值与排序正确，但历史发布文本把 195.10、190.10 显示为 195.1、190.1；部分“只返回数量”问题仍带字段名。这些展示差异保留，不把事实通过等同于格式完全满足。

3 代表问题的输入与复核

sql-051 的输入要求“至少卖出过一首曲目”的艺术家，但统计指标是名下全部曲目。预期查询应将售出资格与全部曲目计数分开，避免销售明细 JOIN 放大数量，或遗漏未售曲目。实际有效记录返回 12 位艺术家，完整行值与独立查询一致。复现时打开 Chinook，检查 EXISTS 销售资格与主查询曲目计数，再比较全部 12 行；不能只看第一条结果判断。

B08 问题要求区分 Central Johnston County 案例的设计能力、研究期平均流量和进出水 TN/TP 平均浓度，且不把许可限值当实测。有效结果为设计 7 MGD，研究期 2005 年 10 月至 2006 年 9 月，实际平均流量 4.12 MGD，进出水 TN 为 31.2/2.14 mg/L，TP 为 5.8/0.26 mg/L。依据是 B08 原 PDF 第 273 和 277 物理页，重点核对 Table 3 的 Average 列与表头[1]。相同问句另在 12 来源范围验证，仍只计一个不同业务问句，两个场景分别保存来源范围和尝试。

工程 A01 公式问题给定 Is(50)=2 MPa，按手册常用换算式 σc=24Is(50)估计单轴抗压强度，预期为 48 MPa。实际有效结果为 48.00 MPa，并保留估算性质与系数适用限制[2]。复现时需要核对原页公式、符号含义及用户参数，不能仅验证 24 乘 2 等于 48。输入值是用户假设，不是手册中的实测岩石记录。

跨源金额问题使用受控合成数据库与口径说明 V1。2024 年已完成订单登记金额合计 10000 分，按 100 分等于 1 元转换为 100 元。系统在参数进入表达式前归一单位，最终表达式 a 避免再次除 100。核验同时检查年份、订单状态、来源字段及 NULL 未知规则；算术正确但范围不对仍不通过。此案例不是企业真实经营业绩。

4 三条真实六轮链

每条链均核对 answer_id、parent_answer_id、conversation_id、turn_index、来源版本和发布内容。已有通过前缀在修复后继续使用，18 轮形成真实有效父链，但没有声称同一最终代码从第一轮全新运行后一次全对。18 轮已经包含在 45 个场景中，不再相加。

表 3　三条链每轮状态与结论摘要

链	六轮顺序	有效记录
同名员工	1 澄清同名；2 西店已知 2 小时；3 东店 3 小时；4 仅 2024 为 2 小时；5 撤销年份恢复 3 小时；6 已知差 1 小时，西店有 1 条缺失。	6/6；首轮为正确澄清
文档库存	1 低于 8 件申请；2 实盘 11/台账 12；3 假设 7 件需申请；4 撤销恢复 11；5 V2.1、签发日期及本站范围；6 总结并确认假设失效。	6/6；总结仍重复分段
跨源金额	1 2025 实际 560 元；2 2024 实际 100 元；3 假设 90 元；4 对比差 470 元；5 撤销恢复 100 元；6 追问来源和计算步骤。	6/6；包含修复后续接

员工链第 1 轮的有效结果是识别同名歧义并请求澄清。第 5 轮撤销年份后核心数值恢复 3 小时，但 time_range 仍编码为 unknown，不能称全部结构槽完善。文档链第 6 轮事实、来源与上下文通过，实际文本分多段并重复采购边界，未满足“一段简明说明”。跨源第 4 轮经历 7 次尝试才取得有效记录；其 470 元是实际值与假设值之差，不是实际同比变化。

跨源第 6 轮从上一真实父轮生成的建议中选择问题，实际问句为“说明这次已核对计算的参数来源与计算步骤？”。复现时应从新父轮的真实建议选择，不能发送冻结计划里的动态占位文字，也不能把历史建议伪称为新实例生成。

5 有效记录与性能口径

45 场景对应 44 个不同问句，保存 86 次提交尝试，其中 84 次发生模型请求、2 次只在本地处理。选用首次记录的场景为 29 个，选用后续记录为 16 个，未选用尝试共 41 条。分阶段代码修订和定向修复影响了结果，因此 45/45 是已有有效记录覆盖，29/45 也不是模型首答准确率。没有调用官方评分软件，不提供官方分数。

545 次内部模型请求包括 467 次普通和 78 次 high，535 次有完整 usage，共 8844583 个已报告 token，10 次用量缺失。HTTP 200 有 535 次，503 有 2 次，8 次未记录；HTTP 成功只表示请求返回。按已知目录价且不扣缓存折扣估算约 10.572514 元，实际账单未知，缺失用量未按零补齐。

表 4　效率测量按层次分开

任务	规模	中位数	范围与口径
本地 SQL 聚合	1000 行	1.007833 ms	后 5 次中位数
本地 SQL 聚合	10000 行	2.418541 ms	后 5 次中位数
本地索引筛选	1000 行	0.675583 ms	不含模型
本地索引筛选	10000 行	1.800875 ms	不含模型
本地检索	同系列	240.5 ms	限定检索范围
本地检索	全 12 文档	776.5 ms	13017 切片
端到端 SQL	10 题	7291.5 ms	4502–19096 ms
端到端 RAG	10 题	9042.5 ms	6394–15197 ms

本地 SQL 每项单独记录首次执行，再取后 5 次中位数。没有清除系统文件缓存，首次值不等于严格冷启动。检索回归与问答也分开：24 题开发回归的全 12 文档 Top10 命中 24/24、必要页 29/29；同系列范围虽 24 题均命中，仍有 1 题未找齐全部必要页，为 28/29 页。召回指标不等于端到端回答准确率。

基础 SQL 组模型请求耗时合计占端到端合计 97.17%，RAG 组为 95.96%。请求时间包含网络、网关和服务处理，无法拆成纯推理。两类基础题端到端中位数为 7.2915 秒和 9.0425 秒，复杂跨源和 12 来源可能明显更慢。12 来源有效记录为 179.884 秒、9 次内部请求；不以基础题中位数代表它。

6 独立复现与当前平台状态

先打开包根目录 00_评审导读.html 离线阅读历史问答。需要独立核对时，再解压 03_作品原始文件.zip，在 README 指定步骤完成首次准备。运行 scripts/prepare_inputs.py 默认只校验 21 个来源 ID 和 44 项数据、原件与模型资产摘要，不创建运行目录、不解析文档、不调用模型。可迁移输入位于评测材料/可迁移复现/，其中离线评分目录与运行知识库隔离。

若需要创建新项目，可在尚未启动的干净目录执行 prepare_inputs.py --prepare --sources chinook,definitions，由实际应用接口生成新的项目与来源映射。已有内容不会被覆盖。多轮新问答必须承接新的 answer-id，不能沿用历史 ID。PDF 和图像在准备脚本中只排队；普通服务启动后可能继续解析，快速查历史结果不需要重新处理 2965 页。

当前已完成 36 项启动、队列、锁和 PID 复用定向检查，CPython 3.13 与 Windows x64 下 45 项精确依赖轮子解析通过；Mac 当前源码的真实启动、健康身份、停止与端口释放通过。没有可用 Windows 实机，安装、DLL 加载、ACL、中文路径界面及 OCR 尚未实际验证。源码适配与依赖解析不替代 Windows 运行证据，Mac 截图也不承担该证明。

7 本次实机展示与定向修复

本次展示单独保存原始请求、实际发布结果与独立核验。SQL 国家销售额前五用时 10.633 秒、4 次内部请求；Python Decimal 从 412 条原始 Invoice 记录复算，全部 5 行与排序一致，NULL 未造成漏算。France 和 Brazil 仍分别显示 195.1、190.1，未完全满足两位小数展示。B08 单来源用时 519.465 秒、12 次内

部请求，7 项核心事实及最终 6 段引用经原 PDF 物理页 273、277 核验一致；第 8 次内部请求输出截断，不能只保留最后成功而删去它。

2025 跨源首轮查得 56000 分、1 条金额 NULL，机械换算 560.00 元，但最终 insufficient_evidence，455.942 秒、13 次请求。原因是独立年份 2025 的匹配误遮了完整日期中的年份，使正确日期无法匹配。修复仅收紧数字边界；新增 12 项专门回归，受影响 11 个文件共 459 项通过，覆盖年份与完整日期共现，以及错日、错年、漏日期和漏实体年份继续拒绝。此数目只属于本次修复，不与历史或 Windows 检查相加。

同问题仅定向复演一次，整轮 571.892 秒、6 次请求，末次触发 480 秒整体 deadline，实际 480.106 秒，最终 failed 且无发布数值。前 5 次已知 usage 为 126790 个 token，超时用量未知。源码同时设读超时与整体上限，账本无自动 POST 重放；客户端停止不证明上游停止处理或计费。

同名员工两轮分别 6.648 秒、3 次普通请求与 14.261 秒、6 次普通请求。先澄清东店编号 1 与西店编号 2，再接收西店编号 2、worklogs.hours 求和及 NULL 未知不补零的明确问题，真实父链、轮号、来源版本一致。已记录工时 2.0 小时正确，另 1 条 NULL 未在正文说明。SQL 无 COALESCE 或 IFNULL，漏报缺失条数不等于补零。

第 7 轮实际发送“把年份改成 2024 年，其余口径不变，仍分别给出原始金额和换算为元的金额。”预留意图为承接 2025 问题，服务记录却是 parent_answer_id 为空、turn_index=1、context_patch 为空。该独立新问 579.717 秒、6 次 high 请求，末次 480.064 秒整体超时，最终 failed，无发布金额或完成澄清。计划与实际父轮差异保留，不能记为继承成功。

失败续问文案随后作最小修复：failed 和 cancelled 不再显示有效父链，提交无父轮与上下文补丁；有效父轮保留版本，queued 与 running 禁重复提交。63 项定向测试通过，其中新增 21 项。Mac 原生 Chrome 与内嵌浏览器累计 15 项交互核验，覆盖范围、原页、草稿与澄清等；其中失败重试在原生浏览器确认全文填入、恢复旧草稿、独立新问及不自动发送，该回放没有新增模型请求。

7 轮合计 50 次内部请求，15 次普通、35 次 high；47 次 completed、1 次 output_truncated、2 次 timeout，HTTP 200 共 48 次、未知 2 次。48 次完整 usage 共 1368224 个 token，2 次超时用量及实际费用未知。用户轮状态为 3 次

completed、1 次 needs_clarification、1 次 insufficient_evidence、2 次 failed。事实与表达限制另列，不并入历史 45 题，不计算稳定性或首答准确率。

源码交接曾在全新解压目录与空运行目录完成 Mac 启停、健康身份、空项目和资源 HTTP 比对，显式复用已有依赖。最终源码包另核对 868 项文件摘要、ZIP 完整性及实际 JS/CSS 响应。前序启停演练与最终资源复核分别留档，均不代表纯净系统安装、Windows 实机或 OCR 验证。

表 5 复现入口与资料用途

位置	用途
00_评审导读.html	题目、完整答案、完整表格、引用与尝试历史
知衡全量问答对照与运行稳定性说明.md	45 场景详细对照和证据口径
当前模型调用策略.md	当前角色设置与历史配置区别
作品根/评测材料/可迁移复现/阅读说明.md	相对路径、来源映射、答案键隔离
作品根/evaluation/acceptance_offline.py	两规模 SQL 生成与测量方法

本说明的数值来自随包历史原件及独立核验索引。查看材料不触发模型调用；主动运行新问题会使用使用者自己的模型配置并生成新记录。新结果应保存到独立目录，与本说明对应的历史尝试分开，以免覆盖已有证据或混合版本。

参考文献

[1] U.S. ENVIRONMENTAL PROTECTION AGENCY. Municipal nutrient removal technologies reference document[R]. EPA 832-R-08-006. Washington, DC: U.S. EPA, 2008.

[2] FEDERAL HIGHWAY ADMINISTRATION. Soils and foundations reference manual: Volume I[R]. FHWA NHI-06-088. Washington, DC: U.S. Department of Transportation, 2006.